

Compte Rendu - TP Chapitre 2 :

Pipelines agiles, versionnement et orchestration avec dlt, dbt et Dagster

Réalisé par : EL MORCHAD Kaoutar – Groupe 2

M1 – Master D'excellence en Intelligence Artificielle

1. Lien GitHub de dossier du projet

https://github.com/Kaoutarelmorchad/tp_chapitre2_pipeline

2. Préparation de l'environnement

a. Création du dossier du projet et activation de l'environnement virtuel

```
PROBLEMS  OUTPUT  DEBUG CONSOLE  TERMINAL  PORTS

PS C:\Users\HP G3> mkdir tp_chapitre2_pipeline

Répertoire : C:\Users\HP G3

Mode                LastWriteTime         Length Name
----                -
d-----          31/05/2026   13:11             tp_chapitre2_pipeline

PS C:\Users\HP G3> cd tp_chapitre2_pipeline
PS C:\Users\HP G3\tp_chapitre2_pipeline> python -m venv .venv
PS C:\Users\HP G3\tp_chapitre2_pipeline> .venv\Scripts\activate
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> |
```

b. Installation des dépendances

```
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> python -m pip install --upgrade pip
Requirement already satisfied: pip in c:\users\hp g3\tp_chapitre2_pipeline\.venv\lib\site-packages (25.3)
WARNING: Cache entry deserialization failed, entry ignored
Collecting pip
  Using cached pip-26.1.1-py3-none-any.whl.metadata (4.6 kB)
Using cached pip-26.1.1-py3-none-any.whl (1.8 MB)
Installing collected packages: pip
  Attempting uninstall: pip
    Found existing installation: pip 25.3
    Uninstalling pip-25.3:
      Successfully uninstalled pip-25.3
  Successfully installed pip-26.1.1
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> pip install dlt dagster dagster-webserver dbt-core dbt-duckdb pandas duckdb pyyaml
Collecting dlt
  Downloading dlt-1.27.2-py3-none-any.whl.metadata (15 kB)
Collecting dagster
  Downloading dagster-1.13.7-py3-none-any.whl.metadata (12 kB)
Collecting dagster-webserver
```

3. Initialisation de Git

a. Initialisation du dépôt Git

```
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> pip freeze > requirements.txt
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git init
Initialized empty Git repository in C:/Users/HP G3/tp_chapitre2_pipeline/.git/
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git config --global init.defaultBranch main
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline>
```

b. Création du fichier .gitignore

```
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> echo .venv/ > .gitignore
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> echo __pycache__/ >> .gitignore
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> echo target/ >> .gitignore
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> echo dbt_packages/ >> .gitignore
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> echo *.duckdb >> .gitignore
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> type .gitignore
.venv/
__pycache__/
target/
dbt_packages/
*.duckdb
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline>
```

c. Premier commit

```
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git add .
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git commit -m "Initialisation du projet pipeline"
[master (root-commit) 90b01b4] Initialisation du projet pipeline
2 files changed, 0 insertions(+), 0 deletions(-)
create mode 100644 .gitignore
create mode 100644 requirements.txt
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline>
```

4. Création des fichiers sources

```

pipeline
• (.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> @"
>> date,produit,categorie,quantite,prix_unitaire,ville
>> 2026-01-01,Clavier,Informatique,2,300,Casablanca
>> 2026-01-02,Souris,Informatique,5,120,Rabat
>> 2026-01-03,Ecran,Informatique,1,2200,Casablanca
>> 2026-01-04,Chaise,Mobilier,3,850,Marrakech
>> 2026-01-05,Bureau,Mobilier,1,1500,Rabat
>> 2026-01-06,Clavier,Informatique,4,300,Tanger
>> 2026-01-07,Chaise,Mobilier,2,850,Casablanca
>> "@ | Out-File -Encoding UTF8 data\ventes.csv
• (.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> type data\ventes.csv
date,produit,categorie,quantite,prix_unitaire,ville
2026-01-01,Clavier,Informatique,2,300,Casablanca
2026-01-02,Souris,Informatique,5,120,Rabat
2026-01-03,Ecran,Informatique,1,2200,Casablanca
2026-01-04,Chaise,Mobilier,3,850,Marrakech
2026-01-05,Bureau,Mobilier,1,1500,Rabat
2026-01-06,Clavier,Informatique,4,300,Tanger
2026-01-07,Chaise,Mobilier,2,850,Casablanca
○ (.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline>

```

5. Étape 1 — Ingestion

```

print('Ingestion terminée : ventes_raw créée dans DuckDB')
• (.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> python pipeline\ingest.py
Ingestion terminée : ventes_raw créée dans DuckDB
○ (.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline>

```

```

• (.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git config --global core.autocrlf true
• (.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git add pipeline\ingest.py
• (.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git commit -m "Ajout de l'étape d'ingestion"
[master 2f5085d] Ajout de l'étape d'ingestion
1 file changed, 16 insertions(+)
create mode 100644 pipeline/ingest.py
○ (.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline>

```

6. Étape 2 — Validation minimale

```

• (.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> python pipeline\validate.py
Validation réussie : schéma et qualité minimale OK

```

```

warning: in the working copy of 'pipeline/validate.py' it will be replaced by one the next time git touches it
• (.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git config --global core.autocrlf true
• (.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git add pipeline\validate.py
• (.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git commit -m "Ajout de l'étape de validation minimale"
[master 574e777] Ajout de l'étape de validation minimale
1 file changed, 27 insertions(+)
create mode 100644 pipeline/validate.py
○ (.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline>

```

7. Étape 3 — Transformation avec dbt


```
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> cd dbt_pipeline
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline\dbt_pipeline> dbt debug --profiles-dir .
14:29:47 Running with dbt=1.11.11
14:29:47 dbt version: 1.11.11
14:29:47 python version: 3.11.0
14:29:47 python path: C:\Users\HP G3\tp_chapitre2_pipeline\.venv\Scripts\python.exe
14:29:47 os info: Windows-10-10.0.19045-SP0
14:29:47 Using profiles dir at .
14:29:47 Using profiles.yml file at .\profiles.yml
14:29:47 Using dbt_project.yml file at C:\Users\HP G3\tp_chapitre2_pipeline\dbt_pipeline\dbt_project.yml
14:29:47 adapter type: duckdb
14:29:48 adapter version: 1.8.2
14:29:48 Configuration:
14:29:48   profiles.yml file [OK found and valid]
14:29:48   dbt_project.yml file [OK found and valid]
14:29:48 Required dependencies:
14:29:48   - git [OK found]
```

```
14:29:48 Connection:
14:29:48   database: ventes
14:29:48   schema: main
14:29:48   path: ../ventes.duckdb
14:29:48   config_options: None
14:29:48   extensions: None
14:29:48   settings: {}
14:29:48   external_root: .
14:29:48   use_credential_provider: None
14:29:48   attach: None
14:29:48   filesystems: None
14:29:48   remote: None
14:29:48   plugins: None
14:29:48   disable_transactions: False
14:29:48 Registered adapter: duckdb=1.8.2
14:29:49 Connection test: [OK connection ok]

14:29:49 All checks passed!
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline\dbt_pipeline>
```

```
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline\dbt_pipeline> dbt run --profiles-dir .
14:56:52 Running with dbt=1.11.11
14:56:53 Registered adapter: duckdb=1.8.2
14:56:53 Unable to do partial parsing because saved manifest not found. Starting full parse.
14:56:56 Found 2 models, 466 macros
14:56:56
14:56:56 Concurrency: 1 threads (target='dev')
14:56:56
14:56:56 1 of 2 START sql view model main.ventes_clean ..... [RUN]
14:56:56 1 of 2 OK created sql view model main.ventes_clean ..... [OK in 0.24s]
14:56:56 2 of 2 START sql view model main.ventes_resume ..... [RUN]
14:56:56 2 of 2 OK created sql view model main.ventes_resume ..... [OK in 0.13s]
14:56:57
14:56:57 Finished running 2 view models in 0 hours 0 minutes and 1.02 seconds (1.02s).
14:56:57
14:56:57 Completed successfully
14:56:57
14:56:57 Done. PASS=2 WARN=0 ERROR=0 SKIP=0 NO-OP=0 TOTAL=2
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline\dbt_pipeline>
```

```

[master abeb9f4] Ajout des modèles dbt
16 files changed, 426 insertions(+)
create mode 100644 dbt_pipeline/.user.yml
create mode 100644 dbt_pipeline/dbt_project.yml
create mode 100644 dbt_pipeline/logs/dbt.log
create mode 100644 dbt_pipeline/models/ventes_clean.sql
create mode 100644 dbt_pipeline/models/ventes_resume.sql
create mode 100644 dbt_pipeline/profiles.yml
create mode 100644 dbt_pipeline/target/compiled/dbt_pipeline/models/ventes_clean.sql
create mode 100644 dbt_pipeline/target/compiled/dbt_pipeline/models/ventes_resume.sql
create mode 100644 dbt_pipeline/target/graph.gpickle
create mode 100644 dbt_pipeline/target/graph_summary.json
create mode 100644 dbt_pipeline/target/manifest.json
create mode 100644 dbt_pipeline/target/partial_parse.msgpack
create mode 100644 dbt_pipeline/target/run/dbt_pipeline/models/ventes_clean.sql
create mode 100644 dbt_pipeline/target/run/dbt_pipeline/models/ventes_resume.sql
create mode 100644 dbt_pipeline/target/run_results.json
create mode 100644 dbt_pipeline/target/semantic_manifest.json
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline>

```

8. Étape 4 — Test simple avec dbt

```

(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline\dbt_pipeline> dbt test --profiles-dir .
15:03:33 Running with dbt=1.11.11
15:03:33 Registered adapter: duckdb=1.8.2
15:03:35 Found 2 models, 3 data tests, 466 macros
15:03:35
15:03:35 Concurrency: 1 threads (target='dev')
15:03:35
15:03:36 1 of 3 START test not_null_ventes_clean_produit ..... [RUN]
15:03:36 1 of 3 PASS not_null_ventes_clean_produit ..... [PASS in 0.22s]
15:03:36 2 of 3 START test not_null_ventes_clean_quantite ..... [RUN]
15:03:36 2 of 3 PASS not_null_ventes_clean_quantite ..... [PASS in 0.13s]
15:03:36 3 of 3 START test not_null_ventes_resume_categorie ..... [RUN]
15:03:36 3 of 3 PASS not_null_ventes_resume_categorie ..... [PASS in 0.12s]
15:03:36
15:03:36 Finished running 3 data tests in 0 hours 0 minutes and 1.08 seconds (1.08s).
15:03:36
15:03:36 Completed successfully
15:03:36
15:03:36 Done. PASS=3 WARN=0 ERROR=0 SKIP=0 NO-OP=0 TOTAL=3
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline\dbt_pipeline>

(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git config --global core.autocrlf true
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git add dbt_pipeline/models/schema.yml
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git commit -m "Ajout des tests simples dbt"
[master 54992a9] Ajout des tests simples dbt
1 file changed, 18 insertions(+)
create mode 100644 dbt_pipeline/models/schema.yml
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline>

```

9. Étape 5 — Orchestration avec Dagster

localhost:3000/runs

dagster

Overview

Runs

Catalog

Jobs

Automation

Lineage

Deployment

Search

Hide navigation

Settings

Support

All Backfills Queued (0) In progress (0) Failed 0:08

Filter Show runs within backfills

Newer Older Actions

ID	Target	Launched by	Status	Created at	Duration	
dbae25d1 View all tags (3)	ventes_pipeline	Manually lau...	Success	31 mai, 16:19	0:00:51	View

```
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git config --global core.autocrlf true
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git add pipeline/orchestrate.py
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git commit -m "Ajout de l'orchestration Dagster"
[master e14f1e8] Ajout de l'orchestration Dagster
1 file changed, 25 insertions(+)
create mode 100644 pipeline/orchestrate.py
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline>
```

10. Étape 6 — CI simple

```
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git config --global core.autocrlf true
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git add .github\workflows\ci.yml
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git commit -m "Ajout d'une CI simple"
[master fbbb192] Ajout d'une CI simple
1 file changed, 29 insertions(+)
create mode 100644 .github/workflows/ci.yml
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline>
```

Kaoutarelmorchad / tp_chapitre2_pipeline

Type to search

Code Issues Pull requests Actions Projects Wiki Security and quality Insights Settings

CI Pipeline

Fix CI cache issue #4 Re-run all jobs

Summary

All jobs

validate-project

Run details

Usage

Workflow file

Triggered via push 1 minute ago

Kaoutarelmorchad pushed 75af110 main

Status Success

Total duration 22s

Artifacts -

ci.yml


on: push

validate-project 20s

11. Historique Git


```
07c32c5...75af110 main -> main
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline> git log --oneline --graph --all
* 75af110 (HEAD -> main, origin/main) Fix CI cache issue
* 07c32c5 Fix CI dependencies
* c497965 Add gitignore cleanup
* 615cfed Fix CI pipeline GitHub Actions
* fb5b192 Ajout d'une CI simple
* e14f1e8 Ajout de l'orchestration Dagster
* 54992a9 Ajout des tests simples dbt
* abeb9f4 Ajout des modèles dbt
* 574e777 Ajout de l'étape de validation minimale
* 2f5085d Ajout de l'étape d'ingestion
* 90b01b4 Initialisation du projet pipeline
(.venv) PS C:\Users\HP G3\tp_chapitre2_pipeline>
```

12. Schéma du pipeline



13. Réponses aux questions

1. En quoi ce pipeline est-il plus structuré qu'un notebook unique ?

Un notebook exécute tout de manière linéaire et manuelle (ingestion, nettoyage, transformation, analyse).

Ici, le pipeline est **modulaire et organisé en étapes séparées** :

- ingestion (ingest.py)
- validation (validate.py)
- transformation (dbt)
- tests (dbt test)
- orchestration (Dagster)

Avantages :

- réutilisable
- testable
- maintenable
- exécutable automatiquement

2. Quel est le rôle de Git dans ce projet ?

Git permet :

- le **versioning du code**
- le suivi des modifications
- la collaboration
- la restauration en cas d'erreur
- l'intégration avec GitHub Actions (CI)

C'est la base de tout projet industriel.

3. Quel est le rôle de requirements.txt ?

Il liste toutes les dépendances Python nécessaires au projet.

Il permet :

- d'installer l'environnement automatiquement (pip install -r)
- de garantir la reproductibilité
- d'éviter les "ça marche sur mon PC"

4. Pourquoi ajouter une étape validate.py ?

Elle sert à vérifier la qualité des données avant transformation :

- valeurs nulles
- incohérences
- formats incorrects
- données invalides

But : éviter de propager des données sales dans le pipeline.

5. Quel est le rôle de dbt test ?

dbt test permet de vérifier automatiquement les règles métier :

- not_null
- unique
- relations entre tables

Il garantit la **qualité et la fiabilité des transformations SQL**.

6. Qu'apporte Dagster par rapport à une exécution manuelle ?

Dagster apporte :

- orchestration des tâches
- gestion des dépendances (ingest → validate → transform → test)
- monitoring des jobs
- exécution reproductible
- logs centralisés

Au lieu de lancer des scripts à la main, tout devient automatisé.

7. Qu'apporte la CI ?

La CI (GitHub Actions) permet :

- tester automatiquement le code à chaque push
- vérifier la syntaxe
- installer les dépendances
- détecter les erreurs tôt

Elle garantit que le projet ne casse jamais en production.

8. Que manque-t-il encore pour un pipeline pleinement industrialisé ?

Ton pipeline est déjà bon, mais il manque encore :

Production-level improvements :

- Docker (containerisation)
- Data warehouse cloud (BigQuery, Snowflake...)
- Logging avancé (ELK, Prometheus)
- Monitoring des pipelines (alerting)
- Scheduling (Airflow/Dagster fully configured)
- Data versioning (DVC)
- Secrets management (.env sécurisé / vault)
- Tests unitaires Python (pytest)
- Deployment automatisé